现代信息检索

Modern Information Retrieval

第2讲 索引构建

Index construction

*改编自”An introduction to Information retrieval”网上公开的课件，地址 http://nlp.stanford.edu/IR-book/

本讲内容

- 怎样构建索引
- 语料通常很大，而服务器内存通常相对较小
  - 在内存有限的情况下的索引构建策略

上一讲介绍过的索引构建过程

解析文档得到词条与文档id对 <term, Doc #>

Doc 1

I did enact Julius Caesar I was killed i' the Capitol; Brutus killed me.

Doc 2

So let it be with Caesar. The noble Brutus hath told you Caesar was ambitious

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

<Term, Doc#>对排序：索引构建关键步骤

在所有文档解析完毕后，倒排索引按照词项排序

主要内容

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Term	Doc #
ambitious	2
be	2
brutus	1
brutus	2
capitol	1
caesar	1
caesar	2
caesar	2
did	1
enact	1
hath	1
I	1
I	1
i'	1
it	2
julius	1
killed	1
killed	1
let	2
me	1
noble	2
so	2
the	1
the	2
told	2
you	2
was	1
was	2
with	2

Reuters RCV1 语料库

- 《莎士比亚全集》规模较小，用来构建索引不能说明问题

- 路透社 1995到1996年一年的英语新闻报道
- 本讲使用Reuters RCV1文档集来介绍可扩展的索引构建技术
  - 虽然RCV1语料不算很大，但可以公开获取。我们将以此语料为例说明索引构建所涉及到的问题

一篇Reuters RCV1文档的样例

REUTERS

You are here: Home > News > Science > Article

Go to a Section: U.S. International Business Markets Politics Entertainment Technology Sports Oddly En

Extreme conditions create rare Antarctic clouds

Tue Aug 1, 2006 3:20am ET

Email This Article | Print This Article | Reprir

[-] Text [-

SYDNEY (Reuters) - Rare, mother-of-pearl colored clouds caused by extreme weather conditions above Antarctica are a possible indication of global warming, Australian scientists said on Tuesday.

Known as nacreous clouds, the spectacular formations showing delicate wisps of colors were photographed in the sky over an Australian

Reuters RCV1语料库的统计信息

N	文档数目	800,000
L	每篇文档的词条数目	200
M	词项数目(= 词类数目)	400,000
	每个词条的字节数（含空格和标点）	6
	每个词条的字节数（不含空格和标点）	4.5
	每个词项的字节数	7.5
T	无位置信息索引中的倒排记录数目	100,000,000

每个词条字节数为4.5 vs. 每个词项平均字节数 7.5，为什么有这样的区别？

基于排序的索引构建方法

- 在构建索引时，每次解析一篇文档
  - 对于每个词项而言，其倒排记录表不到最后一篇文档都是不完整的。
- 如果每个 (termID, docID)对占用8个字节, 那么处理大规模语料需要大量的空间
- 那么能否在最后排序之前将前面产生的倒排记录表全部放在内存中？
  - 答案显然是否定的，特别是对大规模的文档集来说
- 以RCV1为例，T = 100,000,000，这些倒排记录表倒是可以放在一台典型配置的台式计算机的内存中
  - 但是这种基于内存的索引构建方法显然无法扩展到大规模文档集上
- 因此，需要在磁盘上存储中间结果

可扩展的索引构建

- 内存中的索引构建不具备可扩展性
  - 无法将整个语料塞入内存，然后排序，最后将倒排索引写入磁盘
- 怎样为大规模语料构建索引?
- 需要考虑硬件条件限制
  - 内存，硬盘，速度，等等

- 下面回顾一些关于硬件的基本知识

硬件基础知识

IR系统的服务器的典型配置是几十G ～ 上百G的内存（小型服务器），也有几百G或T以上内存的大型服务器.

磁盘空间通常有几T（小型服务器）或数十T（磁盘阵列）.

容错处理的代价非常昂贵：采用多台普通机器会比一台提供容错的机器的价格更便宜

一些硬件基础知识

在内存中访问数据会比从硬盘访问数据**快很多**(大概10倍以上的差距)

硬盘寻道时间是闲置时间：磁头在定位时不发生数据传输（假设使用的是机械硬盘，这也是目前大规模存储的典型配置）

因此：一个大(连续)块的传输会比多个小块(非连续)的传输速度快

硬盘 I/O是基于块的：读写时是整块进行的。块大小：8KB到256 KB不等

一些统计数据(ca. 2008)

符号	含义	值
s	平均寻道时间	5 ms = 5 × 10^{-3} s
b	每个字节的传输时间	0.02 μs = 2 × 10^{-8} s
	处理器时钟频率	10^{9} s^{-1}
P	底层操作时间（e.g.，如word的比较和交换）	0.01 μs = 10^{-8} s
	内存大小	几GB
	磁盘大小	1 TB或更多

即便现在，内存中数据传输依然远快于硬盘I/O

能否将硬盘用作“内存”?

能否将硬盘当作内存使用，实现一种基于硬盘IO的大规模语料索引构建算法?

不能: 对 T = 100,000,000 条记录排序太慢 – 太多的寻道操作.

需要一种外部排序算法

提纲

1. 上一讲回顾
2. 简介
3. BSBI算法
4. SPIMI算法
5. 动态索引构建

BSBI: Blocked sort-based Indexing (一种减少寻道操作的排序)

由解析文档得到8字节（倒排）记录： *(termID, docID)*

需要对 100M 个这样的8字节记录按照termID排序

将所有记录划分为每个大小约为10M的块

能够将10M块全部放入内存

一共有10块

算法基本思想:

收集每一块的倒排记录，排序，将倒排索引写入硬盘

最后将不同的分块合并为一个大的倒排索引

基于块的排序索引构建算法BSBI

```
BSBINDEXCONSTRUCTION()
1  n ← 0
2  while (all documents have not been processed)
3  do n ← n + 1
4     block ← PARSENEXTBLOCK()
5     BSBI-INVERT(block)
6     WRITEBLOCKTODISK(block, f_n)
7  MERGEBLOCKS(f_1, ..., f_n; f_merged)
```

- 该算法中有一个关键决策就是确定块的大小，一般取决于可用内存

对 10个 包含 10M 记录的块排序

首先，将每块读入内存，然后排序:

Quicksort（快速排序）大约需要 O(N ln N) 步

其中，以RCV1为例， N=10M

重复上述步骤10次 - 得到10个已排序的 *runs*，每个包含10M条记录

算法很直接，需要在磁盘中同时保存数据的两份拷贝（合并前与正在合并）

但是可以优化

两个块的合并过程

待合并的倒排记录表

Term id	Doc id
1	d1, d3
2	d1, d2, d4
3	d5
4	d1, d2, d3, d5

Term id	Doc id
1	d6, d7
2	d8, d9
5	d10
6	d8

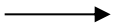

合并后的倒排记录表

Term id	Doc id
1	d1, d3, d6, d7
2	d1, d2, d4, d8, d9
3	d5
4	d1, d2, d3, d5
5	d10
6	d8

合并过程基本不占用内存，但是需要维护一个全局词典

词典： 维护一张词项到整型词项ID的映射表

待合并的倒排记录表： 只包含整型ID，没有字符串

全局词典

term	term id	term	term id
brutus	1	killed	4
caesar	2	noble	5
julius	3	with	6

多个块的合并

- 多项合并(multi-way merge)比两两合并效率更高：从所有块同时读取
  - 同时从所有块读取，并且为每块保持一个读缓冲区(read buffer)，为输出文件（即合并后的索引）保持一个写缓冲区（write buffer）
  - 维护一个待处理termid的优先级队列(priority queue)，每次迭代从队列中选取一个最小的未处理termid
  - 合并不同块中所有的该termID的倒排记录，并写入磁盘

每次迭代均处理较小规模的数据（一个词项的倒排记录）

提纲

1. 上一讲回顾
2. 简介
3. BSBI算法
4. SPIMI算法
5. 动态索引构建

基于排序的索引构建算法的问题

- 假定词典可以在内存中放下
- 通常需要一部词典(动态增长)来将term映射成termID
- 实际上，倒排记录表可以直接采用 term,docID 方式而不是termID,docID方式. . .
- . . . 但是此时中间文件(即待合并倒排记录表)将会变得很大（字符串比整型数空间消耗更大）

内存式单次遍历索引构建算法 SPIMI Single-pass in-memory indexing

- 关键思想 1: 对每个块都产生一个独立的词典 – 不需要在块之间进行term-termID的映射
- 关键思想2: 对倒排记录表不排序（但是对词典排序。实际上由于指针的存在，倒排记录表没有排序的必要），按照它们出现的先后顺序排列

- 在遍历文档的同时，直接在内存中维护一个不断更新的倒排索引
- 基于上述思想可以对每个块生成一个完整的倒排索引
- 这些独立的索引最后合并成一个大索引

两个块的合并过程

待合并的倒排记录表

Term id	Doc id
1	d1, d3
2	d1, d2, d4
3	d5
4	d1, d2, d3, d5

Term id	Doc id
1	d6, d7
2	d8, d9
3	d10
4	d8

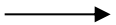

合并后的倒排记录表

Term id	Doc id
1	d1, d3, d6, d7
2	d1, d2, d4, d8, d9
3	d10
4	d8
5	d5
6	d1, d2, d3, d5

Term	Term id
brutus	1
caesar	2
noble	3
with	4

Term	Term id
brutus	1
caesar	2
julius	3
killed	4

待合并的局部词典

term	term id	term	term id
brutus	1	killed	4
caesar	2	noble	5
julius	3	with	6

合并后的全局词典

SPIMI-Invert算法

output_file: 倒排索引；dictionary: 词典
这里假定词典采用哈希表。
在内存中维护局部倒排索引，直至没有更多的空闲内存，将局部索引写入磁盘，释放内存。
合并过程与BSBI类似，但此时没有全局词典提供词项-整数ID的映射，合并过程需要进行词项字符串比较

```
SPIMI-INVERT(token_stream)
 1  output_file ← NEWFILE()
 2  dictionary ← NEWHASH()
 3  while (free memory available)
 4  do token ← next(token_stream)
 5     if term(token) ∉ dictionary
 6        then postings_list ← ADDTODICTIONARY(dictionary, term(token))
 7        else postings_list ← GETPOSTINGSLIST(dictionary, term(token))
 8     if full(postings_list)
 9        then postings_list ← DOUBLEPOSTINGSLIST(dictionary, term(token))
10     ADDTOPOSTINGSLIST(postings_list, docID(token))
11  sorted_terms ← SORTTERMS(dictionary)
12  WRITEBLOCKTODISK(sorted_terms, dictionary, output_file)
13  return output_file
```

Merging of blocks is analogous to BSBI.

两种算法的主要区别

BSBI算法

在分块索引阶段，BSBI算法维护一个全局Term (String) – Termid (int) 的映射表，局部索引为Termid及其倒排记录表，仍然按词典顺序排序。

SPIMI算法

分块索引阶段与BSBI算法不同在于建立局部词典和索引，无需全局词典。在合并阶段，将局部索引两两合并，最后产生全局词典建立Term – Termid的映射。

SPIMI: 压缩

- 如果使用压缩，SPIMI将更加高效
- 词项的压缩
- 倒排记录表的压缩
- 参见下一讲

提纲

1. 上一讲回顾
2. 简介
3. BSBI算法
4. SPIMI算法
5. 动态索引构建

动态索引构建

- 到目前为止，我们都假定文档集是静态的。
- 实际中假设很少成立：文档会增加、删除和修改。
- 这也意味着词典和倒排记录表必须要动态更新。

动态索引构建: 最简单的方法

- 主索引(Main index)+辅助索引(Auxiliary index)
  - 在磁盘上维护一个大的主索引(Main index)
  - 新文档放入内存中较小的辅助索引中
  - 同时搜索两个索引，然后合并结果
  - 定期将辅助索引合并到主索引中

- 删除的处理：
  - 采用无效位向量(Invalidation bit-vector)来表示删除的文档
  - 利用该维向量过滤返回的结果，以去掉已删除文档

主辅索引合并中的问题

- 合并过于频繁
- 合并时如果正好在搜索，那么搜索的性能将很低
- 实际上:
  - 如果每个倒排记录表都采用一个单独的文件来存储的话，那么将辅助索引合并到主索引的代价并没有那么高
  - 此时合并等同于一个简单的添加操作
  - 但是这样做将需要大量的文件，效率显然不高
- 如果没有特别说明，本讲后面都假定索引是一个大文件
- 现实当中常常介于上述两者之间(例如：将大的倒排记录表分割成多个独立的文件，将多个小倒排记录表存放在一个文件当中……)

对数合并(Logarithmic merge)

- 对数合并算法能够缓解(随时间增长)索引合并的开销
- → 用户并不感觉到响应时间上有明显延迟
- 维护一系列索引，其中每个索引是前一个索引的两倍大小
- 将最小的索引（Z_0）置于内存
- 其他更大的索引 （I_0，I_1，．．．）置于磁盘
- 如果 Z_0 变得太大（> n)，则将它作为 I_0 写到磁盘中(如果 I_0 不存在)
- 或者和 I_0 合并(如果 I_0 已经存在），并将合并结果作为I_1写到磁盘中(如果 I_1 不存在），或者和I_1合并(如果 I_0 已经存在)，依此类推……

```
LMergeAddToken(indexes, Z_0, token)
 1  Z_0 ← Merge(Z_0, {token})
 2  if |Z_0| = n
 3    then for i ← 0 to ∞
 4         do if I_i ∈ indexes
 5               then Z_{i+1} ← Merge(I_i, Z_i)
 6                    (Z_{i+1} is a temporary index on disk.)
 7                    indexes ← indexes − {I_i}
 8               else I_i ← Z_i    (Z_i becomes the permanent index I_i.)
 9                    indexes ← indexes ∪ {I_i}
10                    Break
11         Z_0 ← ∅
```

```
LogarithmicMerge()
1  Z_0 ← ∅    (Z_0 is the in-memory index.)
2  indexes ← ∅
3  while true
4  do LMergeAddToken(indexes, Z_0, getNextToken())
```

对数合并的复杂度

- 索引数目的上界为 $O(\log T)$ (T 是所有倒排记录的个数)
- 因此，查询处理时需要合并$O(\log T)$个索引
- 索引构建时间为 $O(T \log T)$.
- 这是因为每个倒排记录需要合并$O(\log T)$次

- 辅助索引方式： 索引构建时间为$O(T^2)$，因为每次合并都需要处理每个倒排记录
- 假 $a + 2a + 3a + 4a + \ldots + na = a\frac{n(n+1)}{2} = O(n^2)$
-

- 因此，对数合并的复杂度比辅助索引方式要低一个数量级

本讲内容

- 两种索引构建算法: BSBI (简单) 和 SPIMI (更符合实际情况)
- 动态索引构建: 如何随着文档集变化更新索引

参考资料

- 《信息检索导论》第4章
- http://ifnlp.org/ir
- Dean and Ghemawat (2004) 有关MapReduce的原作
- Heinz and Zobel (2003) 有关SPIMI的原作
- YouTube视频: Google数据中心