现代信息检索
Modern Information Retrieval

第4讲 通配查询与拼写矫正
Wildcard queries and Spelling Correction

*改编自”An introduction to Information retrieval”网上公开的课件，地址 https://web.stanford.edu/class/cs276/

本讲内容

- 词典的数据结构：访问效率和支持查找的方式
- 通配查询：包含通配符*的查询
- 拼写校正：查询中存在错误时的处理

提纲

词典

通配查询

拼写校正

倒排索引

对每个词项*t*, 保存所有包含*t*的 文档列表。词典的两个基本功能：1、存储词项字符串；2、定位词项

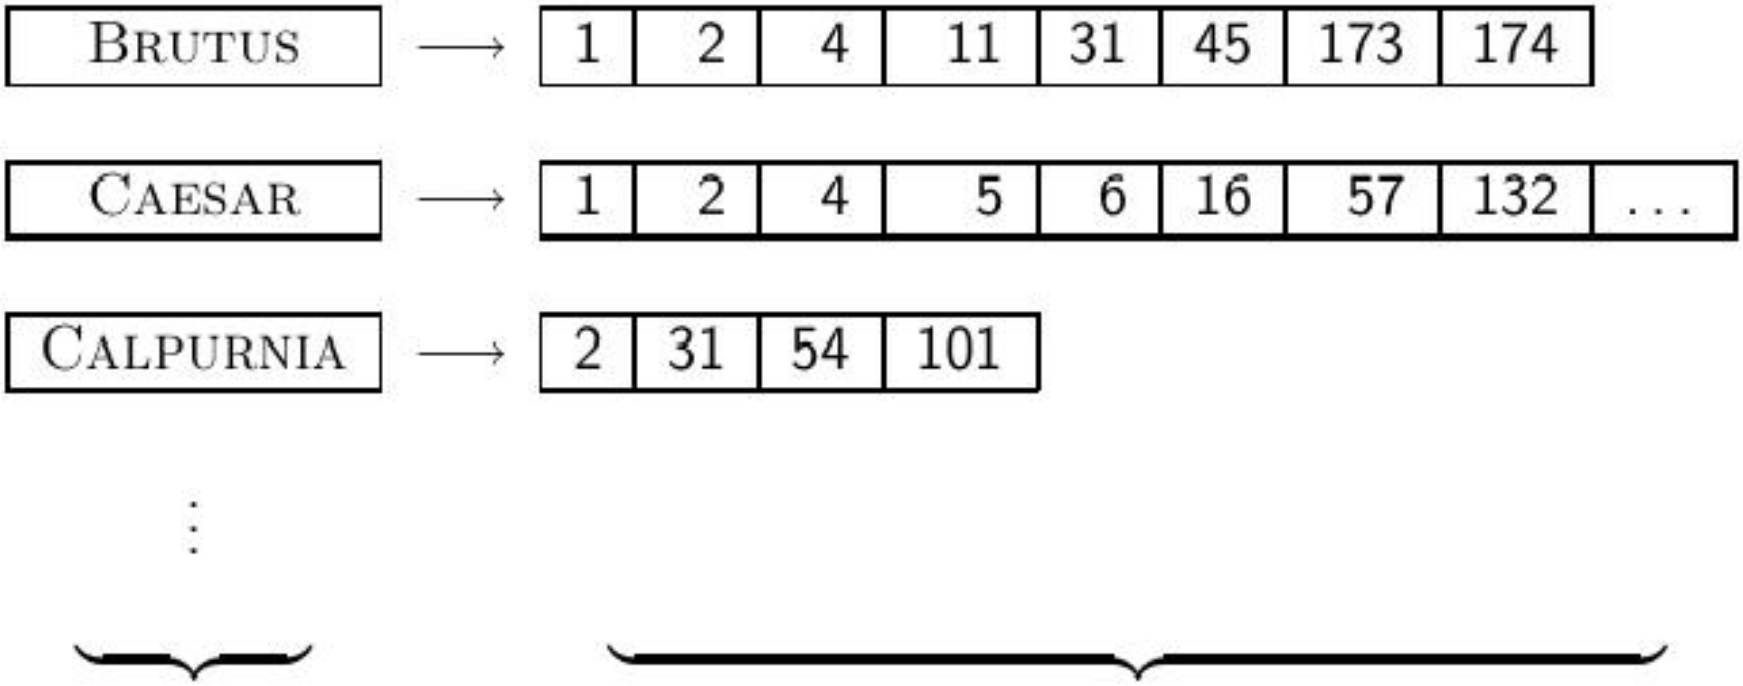

词典(dictionary)　　倒排记录表(posting list)

词典(dictionary)　　倒排记录表(postings)

词典

- 词典是指存储词项词汇表的数据结构
- 词项词汇表(Term vocabulary): 指的是具体数据
- 词典(Dictionary): 指的是数据结构

采用定长数组的词典结构

- 对每个词项，需要存储:
  - 文档频率 (Document Frequency, DF)
  - 指向倒排记录表的指针
  - . . .
- 暂定每条词项的上述信息均采用定长的方式存储
- 假定所有词项的信息采用数组存储

采用定长数组的词典结构

词项	文档频率	指向倒排记录表的指针
a	656 265	→
aachen	65	→
…	…	…
zulu	221	→

空间消耗： 20字节 4字节 4字节

词项定位(即查词典)

- 在词典中查找给定关键字
- 输入“信息”，如何在词典中快速找到这个词？
- 很多词典应用中的基本问题。
- 以下介绍支持快速查找的词典数据结构。

用于词项定位的数据结构

- 主要有两种数据结构：哈希表和树
- 有些IR系统用哈希表，有些系统用树结构
- 采用哈希表或树的准则：
  - 词项数目是否固定或者说词项数目是否持续增长？
  - 词项的相对访问频率如何？
  - 词项的数目有多少？

哈希表

哈希函数，输入词项，输出正整数(通常是地址)

f(信息)=18, f(数据)=19,
f(挖掘)=19

哈希表(Hash Table)

- 每个词项通过哈希函数映射成一个整数
- 尽可能避免冲突
- 查询处理时： 对查询词项进行哈希，如果有冲突，则解决冲突，最后在定长数组中定位
- 优点:
  - 在哈希表中的定位速度快于树中的定位速度
  - 查询时间是常数
- 缺点：
  - 无法处理词项的微小变形 (*resume* vs. *résumé*)
  - 不支持前缀搜索 (比如所有以*automat*开头的词项)
  - 如果词汇表不断增大，需要定期对所有词项重新哈希

树(Tree)

- 树可以支持前缀查找(相当于对词典再建一层索引)
- 最简单的树结构：二叉树
- 搜索速度略低于哈希表方式： $O(\log M)$, 其中 M 是词汇表大小，即所有词项的数目
- $O(\log M)$ 仅仅对平衡树成立
- 使二叉树重新保持平衡开销很大
- B-树 能够减轻上述问题
- B-树定义：每个内部节点的子节点数目在 $[a, b]$之间，其中 a, b 为合适的正整数, e.g., [2, 4].

二叉树

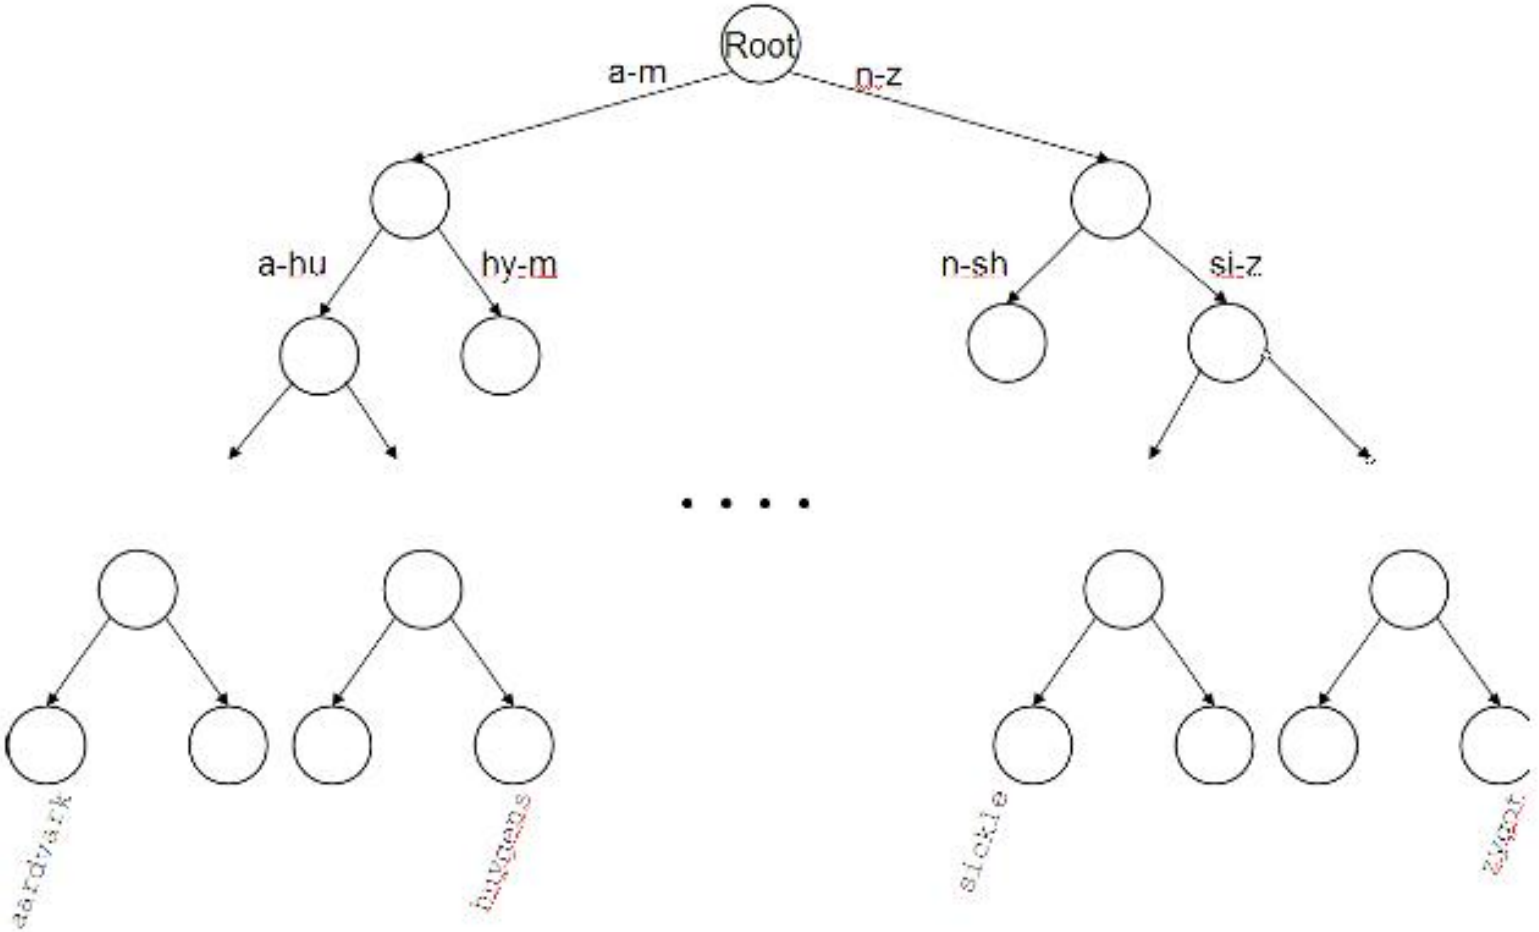

B-树

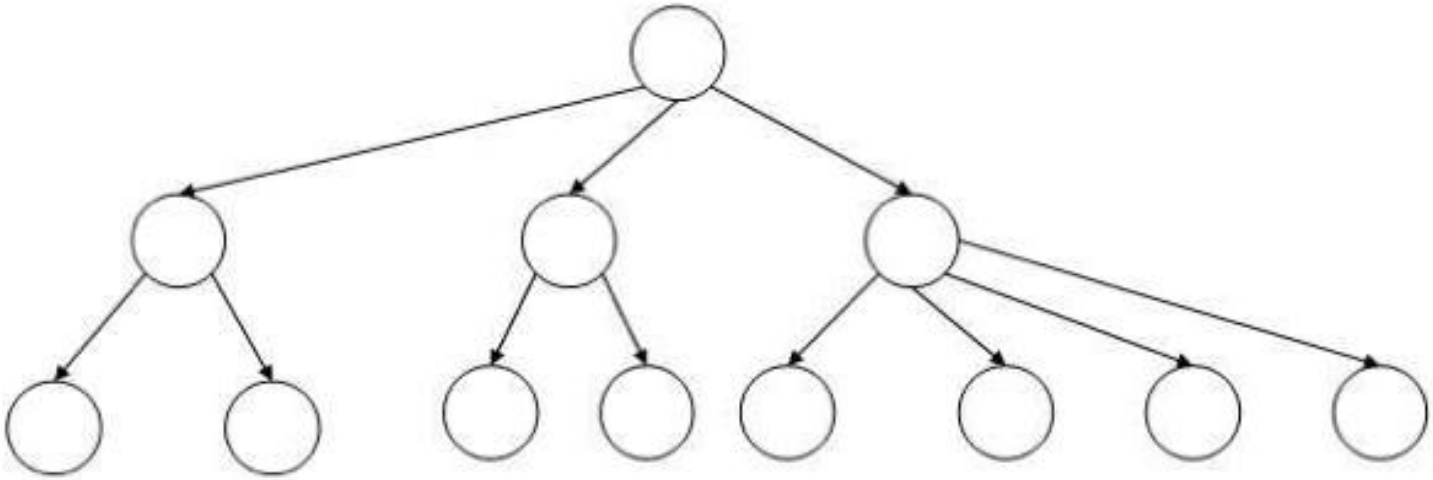

提纲

词典

通配查询

拼写校正

通配查询

- 通配查询：包含通配符的查询，例如：

mon*: 找出所有包含以 *mon*开头的词项的文档
符合条件的词项有：Monday, monster, monitor等

*mon: 找出所有包含以*mon*结尾的词项的文档
符合条件的词项有：summon, common, cinnamon等

通配查询的处理

mon*: 找出所有包含以 *mon*开头的词项的文档

- 如果采用B-树词典结构，那么实现起来非常容易，只需要返回区间mon ≤ t < moo上的词项t

通配查询的处理

*mon: 找出所有包含以*mon*结尾的词项的文档

- 将所有的词项倒转过来，然后基于它们建一棵附加的树
- 返回区间nom ≤ t < non上的词项t

- 比如有以下四个词： absurd, Monday, monster, zoo
- 全部倒转过来： drusba, yadnom, retsnom, ooz
- 然后基于倒转过来的词项再建一颗B 树

- 也就是说，通过上述数据结构，可能得到满足通配查询的一系列词项，然后返回任一词项的文档

词项中间的 *号处理

- 例子: m*nchen
  - 在B-树中分别查找满足m*和 *nchen的词项集合，然后求交集
  - 这种做法开销很大
- 另外一种方法: 轮排(permuterm) 索引
- 基本思想：
  - 将每个通配查询旋转，使*出现在末尾
  - 将每个旋转后的结果存放在词典中，即B-树中
  - 使得任何形式的通配符查询都可以被转换为一个或多个前缀查询

轮排索引

- 对于词项hello: 将 *hello$, ello$h, llohe, lohel, o$hell* 和*$hello* 加入到 B-树中，其中 $ 是一个特殊符号(表示结尾)

- 即在词项前面再加一层索引
- 该索引采用B-树来组织

- 该索引叶节点是词项的各种变形

轮排结果 → 词项的映射示意图

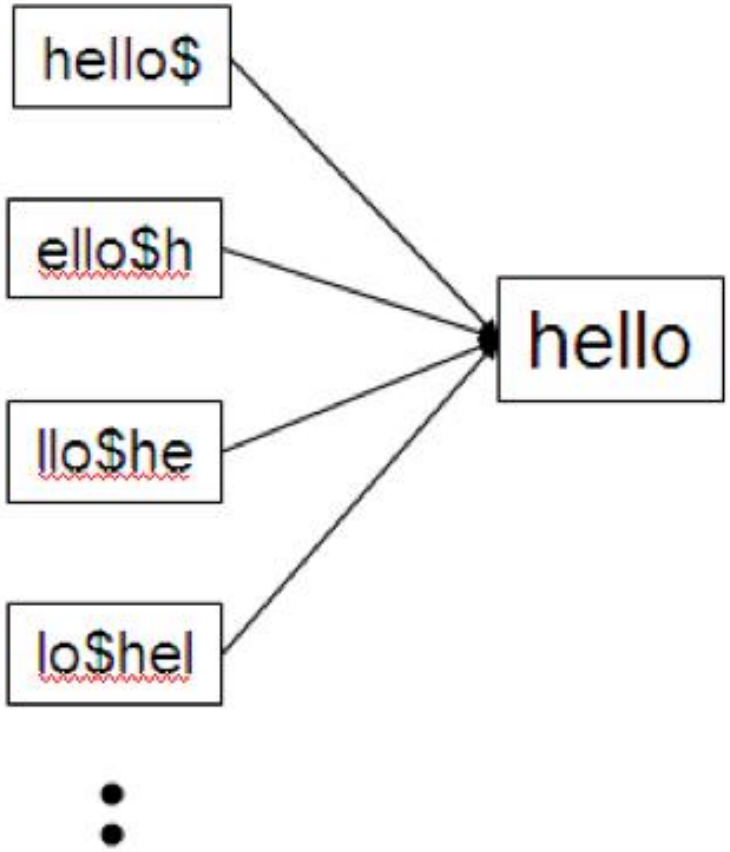

轮排索引

- 对于hello，已经存储了 *hello$, ello$h, llohe, lohel, o$hell*和 *$hello*
- 查询：首先在末尾添加$，然后将*旋转至末尾
  - 对于 X, 查询 X$
  - 对于 X*, 查询 $X*
  - 对于 *X, 查询 X$*
  - 对于 *X*, 查询 X*，比如*ello*，则只需要查到ello开头的串即可(上面是ello$h)，因为此时ello右部一定包含一个$，是否以$结尾与串是否满足查询*X*无关
  - 对于 X*Y, 查询 Y$X*
  - 例子: 假定通配查询为 hel*o, 那么相当于要查询o$hel*
- 轮排索引称为轮排树更恰当
- 但是轮排索引的称呼已经使用非常普遍

轮排索引小结

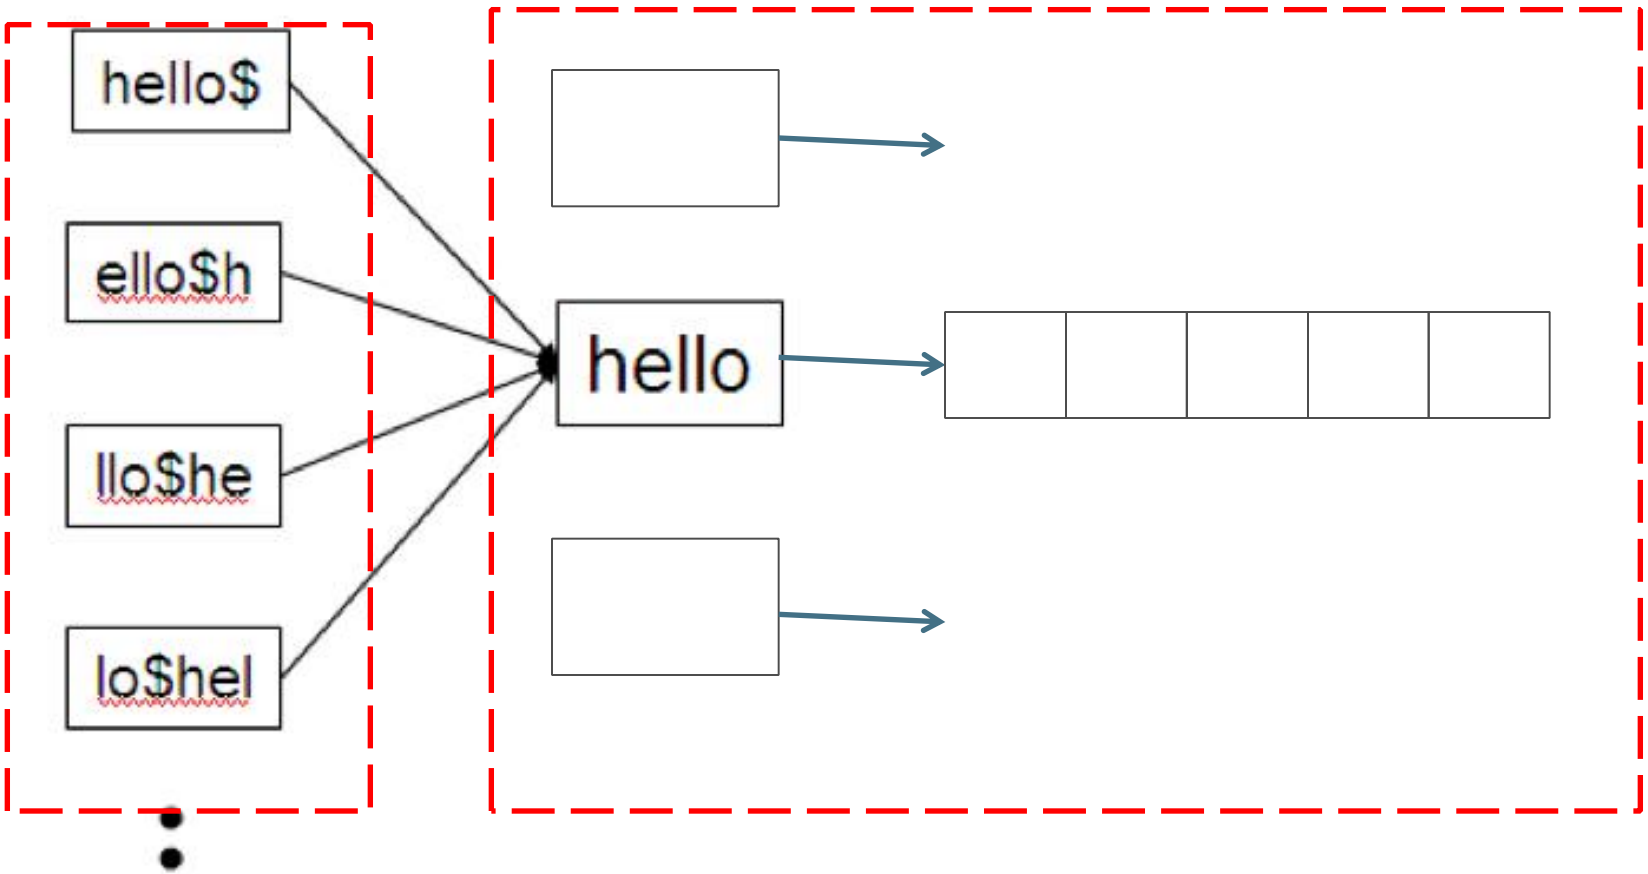

轮排索引（通配查询→词项，采用B树来组织）

传统倒排索引（词项→文档）

使用轮排索引的查找过程

- 将查询进行旋转，将通配符旋转到右部
- 同以往一样查找B-树，得到匹配的所有词项，将这些词项对应的倒排记录表取出
- 问题：相对于通常的B-树，轮排索引(轮排树)的空间要大4倍以上 (经验值)

k-gram 索引

- 比轮排索引空间开销要小
- 枚举一个词项中所有连读的*k*个字符构成***k*-gram** 。
  - 2-gram称为二元组(**bigram**)
  - 3-gram称为三元组(**trigram**)
- 例子: *April is the cruelest month*
  - 2-gram: *$a ap pr ri il l$ $i is s$ $t th he e$ $c cr ru ue el le es st t$ $m mo on nt h$*
  - 同前面一样，$ 是一个特殊字符，表示单词开始或结束

k-gram索引

- 构建一个倒排索引，此时词典部分是所有的k-gram，倒排记录表部分是包含某个k-gram的所有词项
- 相当于对词项再构建一个倒排索引(二级索引)

k-gram (bigram, trigram, . . .) 索引

- 需要注意的是，这里有两个倒排索引
- 词典-文档的倒排索引基于词项返回文档
- 而*k*-gram索引用于查找词项，即基于查询所包含的*k*-gram来查找所有的词项

利用2-gram索引处理通配符查询

- 例子：查询mon*
  - 先执行布尔查询: $m AND mo AND on
  - 该布尔查询会返回所有以前缀*mon*开始的词项 . . .
  - . . . 当然也可能返回许多伪正例(false positives)，比如MOON。同前面的双词索引处理短语查询一样，满足布尔查询只是满足原始查询的必要条件。因此，必须要做后续的过滤处理
  - 剩下的词项将在词项-文档倒排索引中查找文档
- *k*-gram索引 vs. 轮排索引
  - *k*-gram索引的空间消耗小
  - 轮排索引不需要进行后过滤

课堂练习

- Google对通配符查询的支持极其有限
- 比如：在 Google中查询 [gen* universit*]
  - 意图：想查 University of Geneva, 但是不知道如何拼写，特别是法语中的拼写
- 按照Google自己的说法, 2010-04-29: “* 操作符只能作为一个整体单词使用，而不能作为单词的一部分使用”
- 问题: 为什么Google对通配查询并不充分支持？

原因

- 问题 1: 一条通配符查询往往相当于执行非常多的布尔查询
  - 对于 [gen* universit*]: geneva university OR geneva université OR genève university OR genève université OR general universities OR . . .
  - 开销非常大

- 问题 2: 用户不愿意更多的敲击键盘
  - 如果允许[pyth* theo*]代替 [pythagoras' theorem]的话，用户会倾向于使用前者
  - 这样会大大加重搜索引擎的负担
  - Google Suggest是一种减轻用户输入负担的好方法
    - 查询提示，百度等引擎也有类似功能

提纲

词典

通配查询

拼写校正

拼写矫正的应用

文字处理

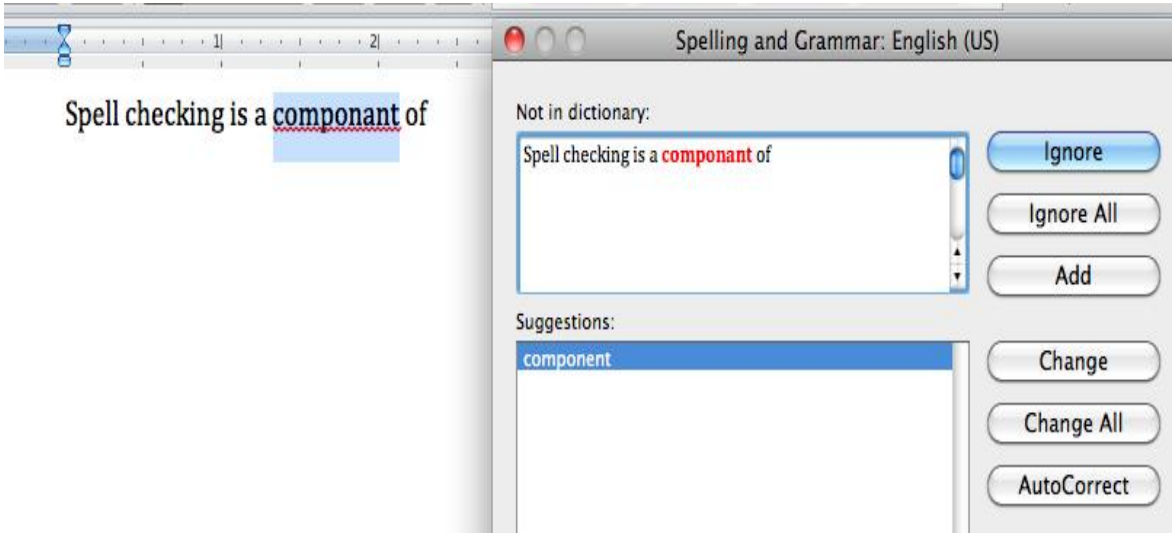

手机

Web搜索

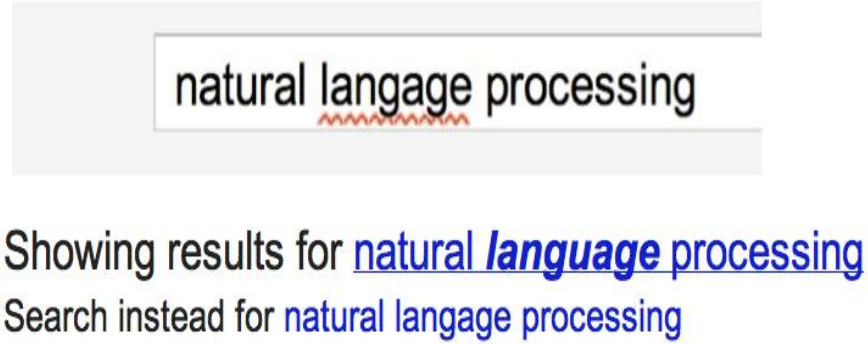

拼写错误率

拼写错误率取决于具体的应用，大约在 ~1 - 20% 之间

26%: Web queries Wang *et al.* 2003

13%: Retyping, no backspace: Whitelaw *et al.* English&German

输入一篇Wikipedia文章，不能使用回退/删除

7%: 手机输入，允许纠正

2%: 手机输入，不允许纠正 Soukoreff &MacKenzie 2003

1-2%: 正常键盘输入: Kane and Wobbrock 2007, Gruden et al. 1983

拼写涉及的任务

拼写错误检测

拼写错误矫正:

- 自动矫正
  - hte→the
- 矫正提示：提示矫正选项
- 提示列表：给出矫正候选列表

拼写错误种类

非词汇 (non-word) 错误

graffe →giraffe (长颈鹿)

真实词汇(real-word) 错误

排印错误

three →there

认知错误（同/近音词）

piece→peace,

too → two

your →you're

非词汇错误的纠正一般来说不考虑上下文

而真实词汇错误的纠正通常需要考虑上下文

拼写校正

- 两个主要用途
  - 纠正待索引文档
  - 纠正用户的查询
- 两种拼写校正的方法
- 词独立(Isolated word)法
  - 只检查每个单词本身的拼写错误
  - 如果某个单词拼写错误后变成另外一个单词，则无法查出，e.g., *an asteroid that fell **form** the sky*
- 上下文敏感(Context-sensitive)法
  - 纠错时要考虑周围的单词
  - 能纠正上例中的错误 *form/from*

非词汇拼写错误

非词汇拼写错误检测:

- **词典**中不存在的词均视为错误
- 一般来说，词典越大越好
- (Web很大，但是充满了拼写错误，因此并不是一个很好的词典)

非词汇拼写错误矫正

- 产生**候选**：与错误书写的单词相似的真实词汇
- 选择最好的候选词:
  - 最短加权编辑距离
  - 最高噪声通道概率

真实词汇 与 非词汇 拼写错误

对每个单词 *w*, 产生候选集:

- 找到**发音**相似的候选词
- 找到**拼写**相似的候选词
- 将 *w* 也包括在候选集里

选择最佳候选词

- 将拼写错误视为（正确单词）经过噪声通道的输出
- 上下文敏感 – 需要考虑周围的文字是否合适，例如：
- *Flying form Heathrow to LAX → Flying from Heathrow to LAX*

相关术语

我们之前讲过 字符二元组和*k*元组（*character bigrams and k-grams*）:

st, pr, an …

同时也有 词项二元组和*n*元组（*word bigrams and n-grams*）:

palo alto, flying from, road repairs

词独立拼写矫正

INDEPENDENT WORD SPELLING CORRECTION

拼写噪声通道模型

The Noisy Channel Model of Spelling

噪声通道（noisy channel）

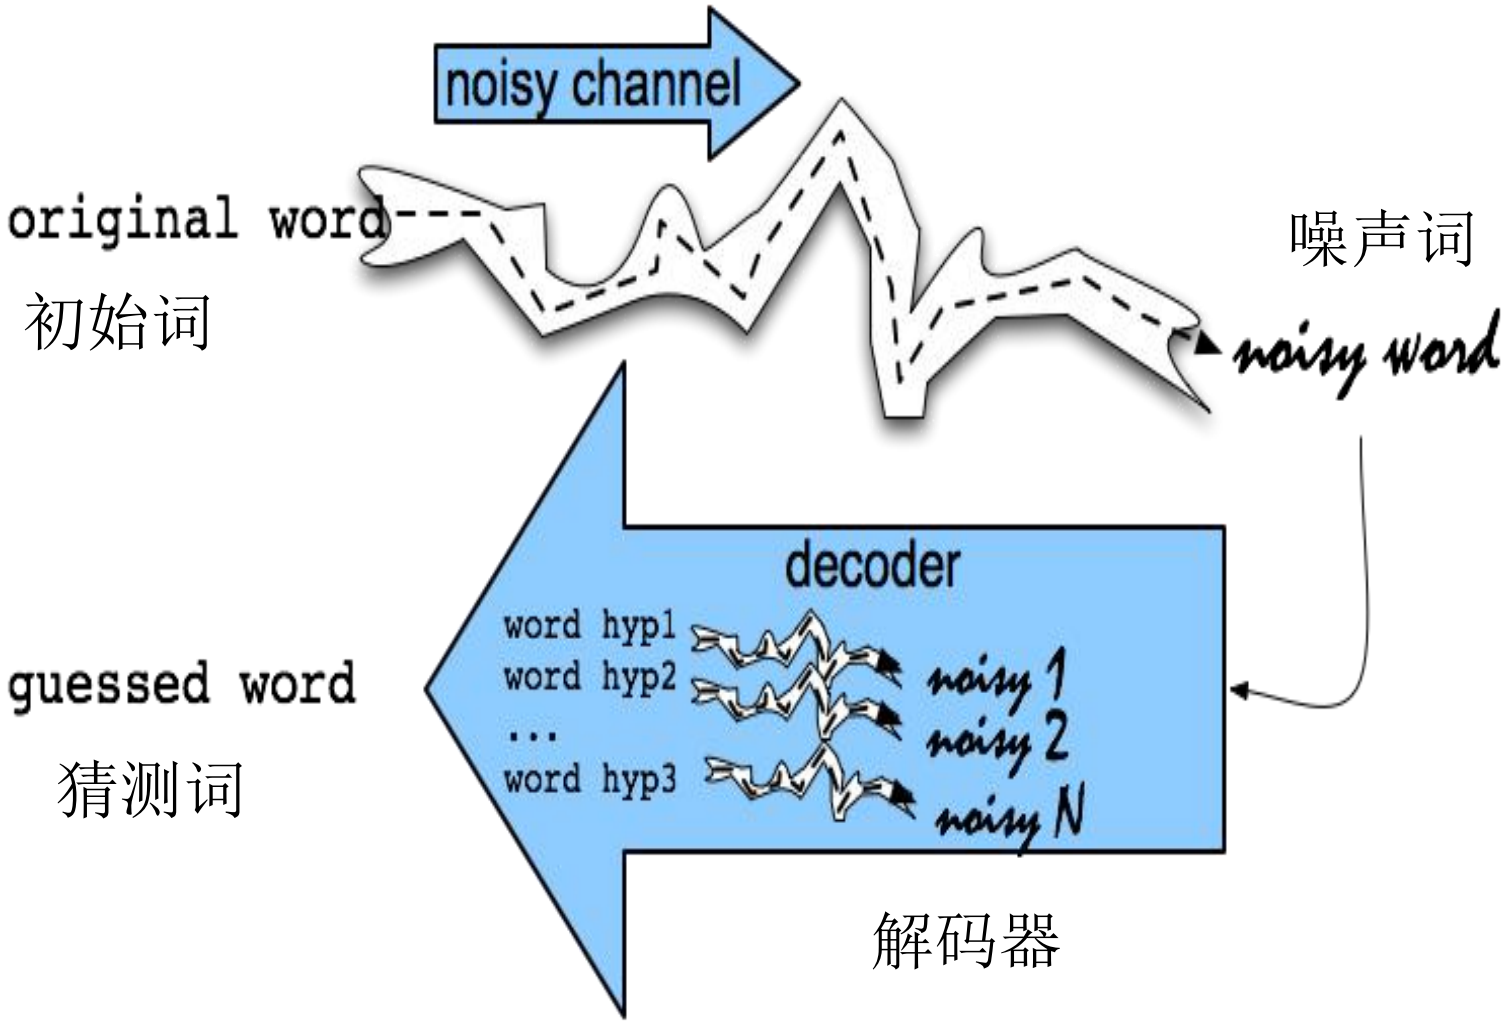

噪声通道 = 贝叶斯定理

观察到一个拼写错误的单词 x

找到正确词项 $\hat{w}$

在所有词项中寻找$\hat{w}$，
使得概率$P(w|x)$最大

$$\hat{w} = \underset{w \in V}{\operatorname{argmax}} P(w|x)$$

$$= \underset{w \in V}{\operatorname{argmax}} \frac{P(x|w)P(w)}{P(x)}$$

Bayes

$$= \underset{w \in V}{\operatorname{argmax}} P(x|w)P(w)$$

Prior

Noisy channel model

基于噪声通道的拼写矫正模型大约在1990年提出

IBM

Mays, Eric, Fred J. Damerau and Robert L. Mercer. 1991. Context based spelling correction. *Information Processing and Management*, 23(5), 517–522

AT&T Bell Labs

Kernighan, Mark D., Kenneth W. Church, and William A. Gale. 1990. A spelling correction program based on a noisy channel model. Proceedings of COLING 1990, 205-210

非词汇拼写错误的例子

acress - access?

候选词产生：两种情况

拼写相近的词

（与拼写错误词）编辑距离(*edit distance*) 较小的词

flom - from: edit distance=1

发音接近的词

候选词评价: Damerau-Levenshtein编辑距离

两个字符串的最小编辑距离。算法定义了四种操作：

Insertion （插入） informatin - information

Deletion （删除） informationn - information

Substitution （替换）infoemation - information

Transposition of two adjacent letters

（两个相邻字母的交换） infromation - information

与 acress编辑距离为1的词

Error	Candidate Correction	Correct Letter	Error Letter	Type
acress	actress	t	-	deletion
acress	cress	-	a	insertion
acress	caress	ca	ac	transposition
acress	access	c	r	substitution
acress	across	o	e	substitution
acress	acres	-	s	insertion

候选词产生

80% 的拼写错误到正确拼写的编辑距离 = 1

几乎所有拼写错误到正确拼写的编辑距离 <= 2

除上述4种操作外，还可允许插入 **空格** 或 **连接符**

thisidea → this idea

inlaw → in-law

可允许词项合并

data base → database

（上述两种操作使得）对于查询这样的短文本，可以将其视为一个完整的词项来检查拼写

怎样产生候选词?几种方法

1. 遍历词典，计算每一个词的编辑距离
2. 生成所有编辑距离 ≤ *k* (例如, *k* = 1 或 2)的词，然后与词典取交集
3. 建立一个字符*k-gram*索引，从词典中找到共享最多*k-grams*的词项（例如，基于Jaccard系数计算）

   see *IIR* sec 3.3.4

4. 使用Levenshtein 有限状态转换机（Levenshtein finite state transducer）快速计算
5. 预先计算一个词项到可能的 正确词项/拼写错误 的映射表

一个（拼写矫正）范式 …

找到最好的拼写矫正计算代价高，因此替代方案是

- 找到一个包含较高质量的拼写矫正子集
  - (例如编辑距离小于2)
- 从中选择最好的候选词

子集也许并不包括实际上的最优候选词

这是IR中一种常见范式，例如：

- 找到与查询最相关的文档, 找到与问题最符合的答案, 找到与用户最相关的广告 …
- 首先找到一个好的候选集（find a good candidate set）
- 然后从中找到最优的前K个答案（Find the top *K amongst them* and return them as the best）

产生候选集: 回到贝叶斯定理

若有拼写错误的单词 x

找到其正确拼写 $\hat{w}$

$$\hat{w} = \underset{w \in V}{\operatorname{argmax}} P(w \mid x)$$

$$= \underset{w \in V}{\operatorname{argmax}} \frac{P(x \mid w) P(w)}{P(x)}$$

$$= \underset{w \in V}{\operatorname{argmax}} P(x \mid w) P(w)$$

What's $P(w)$?

Language Model（语言模型）

若有包含T个词条的大文本语料;

且*C(w)* = # occurrences of *w*

$$P(w)=\frac{C(w)}{T}$$

在其它应用中，如果（静态）词典不能满足需要，可以采用经过适当过滤的用户输入查询训练语言模型。

Unigram Prior probability（一元先验概率）

Counts from 404,253,213 words in Corpus of Contemporary English (COCA)

word	Frequency of word	*P(w)*
actress	9,321	.0000230573
cress	220	.0000005442
caress	686	.0000016969
access	37,038	.0000916207
across	120,844	.0002989314
acres	12,874	.0000318463

通道模型概率
Channel model probability

Error model probability(错误模型概率), Edit probability (编辑概率)

Kernighan, Church, Gale 1990

错误词项 $x = x_1, x_2, x_3 \ldots x_m$

正确词项 $w = w_1, w_2, w_3, \ldots, w_n$

$P(x|w)$ = probability of the edit

(deletion/insertion/substitution/transposition)

计算错误概率：混淆“矩阵”

```
del[x,y]:     count(xy typed as x)
ins[x,y]:     count(x typed as xy)
sub[x,y]:     count(y typed as x)
trans[x,y]:   count(xy typed as yx)
```

插入（ins）和删除（del）的概率条件依赖前一个字符

替换（sub）操作的混淆矩阵

sub[X, Y] = Substitution of X (incorrect) for Y (correct)

X	Y (correct)																								
	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	q	r	s	t	u	v	w	x	y	z
a	0	0	7	1	342	0	0	2	118	0	1	0	0	3	76	0	0	1	35	9	9	0	1	0	5	0
b	0	0	9	9	2	2	3	1	0	0	0	5	11	5	0	10	0	0	2	1	0	0	8	0	0	0
c	6	5	0	16	0	9	5	0	0	0	1	0	7	9	1	10	2	5	39	40	1	3	7	1	1	0
d	1	10	13	0	12	0	5	5	0	0	2	3	7	3	0	1	0	43	30	22	0	0	4	0	2	0
e	388	0	3	11	0	2	2	0	89	0	0	3	0	5	93	0	0	14	12	6	15	0	1	0	18	0
f	0	15	0	3	1	0	5	2	0	0	0	3	4	1	0	0	0	6	4	12	0	0	2	0	0	0
g	4	1	11	11	9	2	0	0	0	1	1	3	0	0	2	1	3	5	13	21	0	0	1	0	3	0
h	1	8	0	3	0	0	0	0	0	0	2	0	12	14	2	3	0	3	1	11	0	0	2	0	0	0
i	103	0	0	0	146	0	1	0	0	0	0	6	0	0	49	0	0	0	2	1	47	0	2	1	15	0
j	0	1	1	9	0	0	1	0	0	0	0	2	1	0	0	0	0	0	5	0	0	0	0	0	0	0
k	1	2	8	4	1	1	2	5	0	0	0	0	5	0	2	0	0	0	6	0	0	0	4	0	0	3
l	2	10	1	4	0	4	5	6	13	0	1	0	0	14	2	5	0	11	10	2	0	0	0	0	0	0
m	1	3	7	8	0	2	0	6	0	0	4	4	0	180	0	6	0	0	9	15	13	3	2	2	3	0
n	2	7	6	5	3	0	1	19	1	0	4	35	78	0	0	7	0	28	5	7	0	0	1	2	0	2
o	91	1	1	3	116	0	0	0	25	0	2	0	0	0	0	14	0	2	4	14	39	0	0	0	18	0
p	0	11	1	2	0	6	5	0	2	9	0	2	7	6	15	0	0	1	3	6	0	4	1	0	0	0
q	0	0	1	0	0	0	27	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
r	0	14	0	30	12	2	2	8	2	0	5	8	4	20	1	14	0	0	12	22	4	0	0	1	0	0
s	11	8	27	33	35	4	0	1	0	1	0	27	0	6	1	7	0	14	0	15	0	0	5	3	20	1
t	3	4	9	42	7	5	19	5	0	1	0	14	9	5	5	6	0	11	37	0	0	2	19	0	7	6
u	20	0	0	0	44	0	0	0	64	0	0	0	0	2	43	0	0	4	0	0	0	0	2	0	8	0
v	0	0	7	0	0	3	0	0	0	0	0	1	0	0	1	0	0	0	8	3	0	0	0	0	0	0
w	2	2	1	0	1	0	0	2	0	0	1	0	0	0	0	7	0	6	3	3	1	0	0	0	0	0
x	0	0	0	2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	9	0	0	0	0	0	0	0
y	0	0	2	0	15	0	1	7	15	0	0	0	2	0	6	1	0	7	36	8	5	0	0	1	0	0
z	0	0	0	7	0	0	0	0	0	0	0	7	5	0	0	0	0	2	21	3	0	0	0	0	3	0

邻近键

混淆矩阵构建也可以考虑键盘的邻近型，例如M容易被误打成N

混淆矩阵生成

Peter Norvig's list of errors

Peter Norvig's list of counts of single-edit errors

All Peter Norvig's ngrams data links: http://norvig.com/ngrams/

Channel model （噪声通道模型）

$$P(x|w) = \begin{cases} \frac{\text{del}[w_{i-1}, w_i]}{\text{count}[w_{i-1} w_i]}, & \text{if deletion} \\ \frac{\text{ins}[w_{i-1}, x_i]}{\text{count}[w_{i-1}]}, & \text{if insertion} \\ \frac{\text{sub}[x_i, w_i]}{\text{count}[w_i]}, & \text{if substitution} \\ \frac{\text{trans}[w_i, w_{i+1}]}{\text{count}[w_i w_{i+1}]}, & \text{if transposition} \end{cases}$$

加一概率平滑（add-1 probability smoothing）

上述混淆矩阵的例子很难避免某种操作样本数为0

这样会导致零概率问题：概率P(x|w)为0

一个简单的解决方案是加一平滑：将所有的计数+1。若有一个包含 |A|个 字母的词表, 平滑后的概率:

$$\text{If substitution, } P(x \mid w) = \frac{\text{sub}[x, w] + 1}{\text{count}[w] + A}$$

单词 acress的通道模型

Candidate Correction	Correct Letter	Error Letter	x/w	P(x/w)
actress	t	-	c|ct	.000117
cress	-	a	a|#	.00000144
caress	ca	ac	ac|ca	.00000164
access	c	r	r|c	.000000209
across	o	e	e|o	.0000093
acres	-	s	es|e	.0000321
acres	-	s	ss|s	.0000342

Candidate Correction	Correct Letter	Error Letter	x|w	P(x|w)	P(w)	10^9 * P(x|w)* P(w)
actress	t	-	c|ct	.000117	.0000231	2.7
cress	-	a	a|#	.00000144	.000000544	.00078
caress	ca	ac	ac|ca	.00000164	.00000170	.0028
access	c	r	r|c	.000000209	.0000916	.019
across	o	e	e|o	.0000093	.000299	2.8
acres	-	s	es|e	.0000321	.0000318	1.0
acres	-	s	ss|s	.0000342	.0000318	1.0

Candidate Correction	Correct Letter	Error Letter	x/w	P(x/w)	P(w)	10^9 *P(x/w)P(w)
actress	t	-	c|ct	.000117	.0000231	2.7
cress	-	a	a|#	.00000144	.000000544	.00078
caress	ca	ac	ac|ca	.00000164	.00000170	.0028
access	c	r	r|c	.000000209	.0000916	.019
across	**o**	**e**	**e|o**	**.0000093**	**.000299**	**2.8**
acres	-	s	es|e	.0000321	.0000318	1.0
acres	-	s	ss|	.0000342	.0000318	1.0

评价：一些拼写矫正数据集

- Wikipedia's list of common English misspelling
- Aspell filtered version of that list
- Birkbeck spelling error corpus
- Peter Norvig's list of errors (includes Wikipedia and Birkbeck, for training or testing)

SPELLING CORRECTION WITH THE NOISY CHANNEL
噪声通道拼写矫正

Context-Sensitive Spelling Correction
上下文敏感的拼写矫正

实际应用中的拼写错误

…leaving in about fifteen ***minuets*** ***(小舞蹈节目？)*** to go to her house. minutes

The design ***an*** construction of the system… a

Can they ***lave*** ***(洗澡？)*** him my messages? leave

The study was conducted mainly ***be*** John Black. by

25-40% 的拼写错误是真实词汇　Kukich 1992

对于这一类拼写错误，需要考虑上下文

上下文敏感的拼写矫正

For each word in sentence (phrase, query …)

- Generate *candidate set* （*产生候选集*）
  - the word itself （单词本身）
  - all single-letter edits that are English words （所有经过单字母编辑后是英文单词的单词）
  - words that are homophones （同音异形异义词）
  - (all of this can be pre-computed! 这些都可以预先线下计算)

Choose best candidates （选择最佳候选词）

- Noisy channel model （采用噪声通道模型）

真实词汇拼写矫正的噪声通道

- 给定句子 $x_1,x_2,x_3,\ldots,x_n$
- 为每个词 x_i 产生一个候选词集合
  - Candidate(x_1) = {x_1, w_1 , w'_1 , w''_1 ,…}
  - Candidate(x_2) = {x_2, w_2 , w'_2 , w''_2 ,…}
  - Candidate(x_n) = {x_n, w_n , w'_n , w''_n ,…}
- 选择序列 W 使得 $P(W|x_1,\ldots,x_n)$最大

$$\hat{w} = \underset{w \in V}{\operatorname{argmax}} P(w \mid x)$$

$$= \underset{w \in V}{\operatorname{argmax}} P(x \mid w) P(w)$$

结合上下文词汇：上下文敏感的单词矫正

要决定正确的单词是 **actress** 还是 **across** （两者都是真实词汇）需要考虑上下文

需要一个更好的 **language model（语言模型）**

- 在自然语言处理/计算语言学课程中会涉及到很多相关的知识
- 这里仅仅简单介绍语言模型的基础知识

bigram language model（二元语言模型）中文本片段$w_1 \ldots w_n$的概率的计算：w_i的概率仅仅取决于前一个单词

$$P(w_1 \ldots w_n) = P(w_1)P(w_2|w_1)\ldots P(w_n|w_{n-1})$$

结合上下文词汇

对于一元词项频率, $P(w)$ 始终非零

因为词典是从文本语料本身产生的

但是 $P(w_k|w_{k-1})$并非如此，因此需要 **平滑**

可以使用加一平滑

但是一种更好的方法是将一元模型与二元模型插值:

$$P_{li}(w_k|w_{k-1}) = \lambda P_{uni}(w_k) + (1-\lambda)P_{bi}(w_k|w_{k-1})$$

$$P_{bi}(w_k|w_{k-1}) = C(w_{k-1}, w_k) / C(w_{k-1})$$

几个需要注意的要点

我们有几种单词(一元，二元)的概率分布

Keep them straight!（使用直接的概率似然估计）

使用对数概率:

$\log P(w_1 \ldots w_n) = \log P(w_1) + \log P(w_2|w_1) + \ldots + \log P(w_n|w_{n-1})$

否则会有浮点下溢的问题 （floating point underflow）

查询词可能会在一篇文档中到处出现

首先统计一元词项频率，同时统计二元词项频率

通常人们会在字符串之前使用一个“$”字符表示字符串的开头，但是在拼写矫正中并不需要这样做

因此，需要注意的是，一元和二元词项的词频总和并不相等 - 虽然这本身并不是一个问题

使用二元语言模型

"a stellar and versatile **acress** whose combination of sass and glamour…"

基于现代美国英语语料，使用加一平滑得到的二元词项概率：

P(actress|versatile)=.000021 P(whose|actress) = .0010

P(across|versatile) =.000021 P(whose|across) = .000006

P("versatile actress whose") = .000021*.0010 = 210 $x10^{-10}$

P("versatile across whose") = .000021*.000006 = 1 $x10^{-10}$

使用二元语言模型

"a stellar and versatile **acress** whose combination of sass and glamour…"

基于现代美国英语语料，使用加一平滑得到的二元词项概率：

P(actress|versatile)=.000021 P(whose|actress) = .0010

P(across|versatile) =.000021 P(whose|across) = .000006

P("versatile actress whose") = .000021*.0010 = 210 x10^{-10}

P("versatile across whose") = .000021*.000006 = 1 x10^{-10}

真实词汇拼写矫正的噪声通道模型

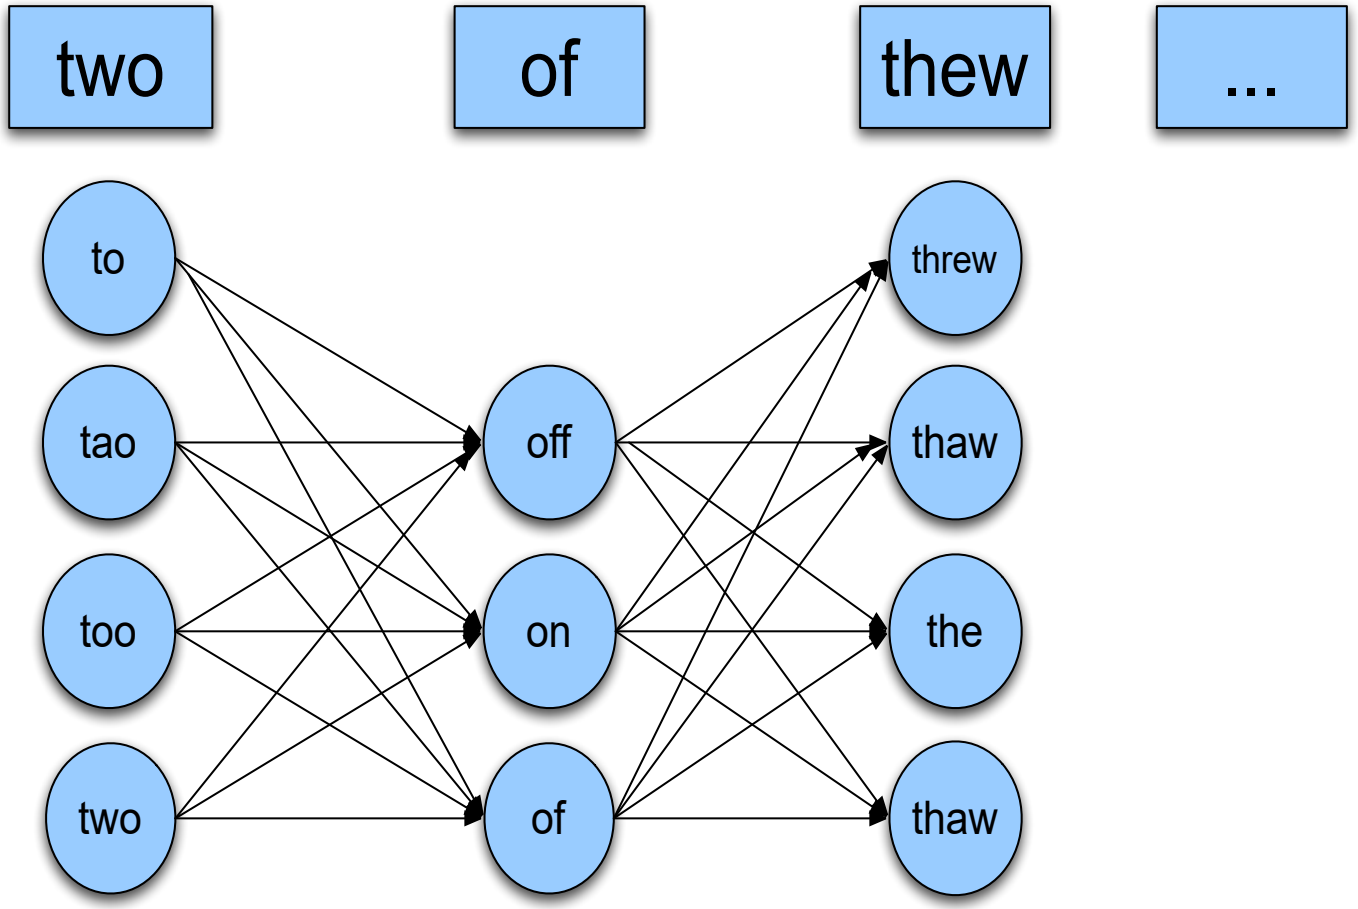

真实词汇拼写矫正的噪声通道模型

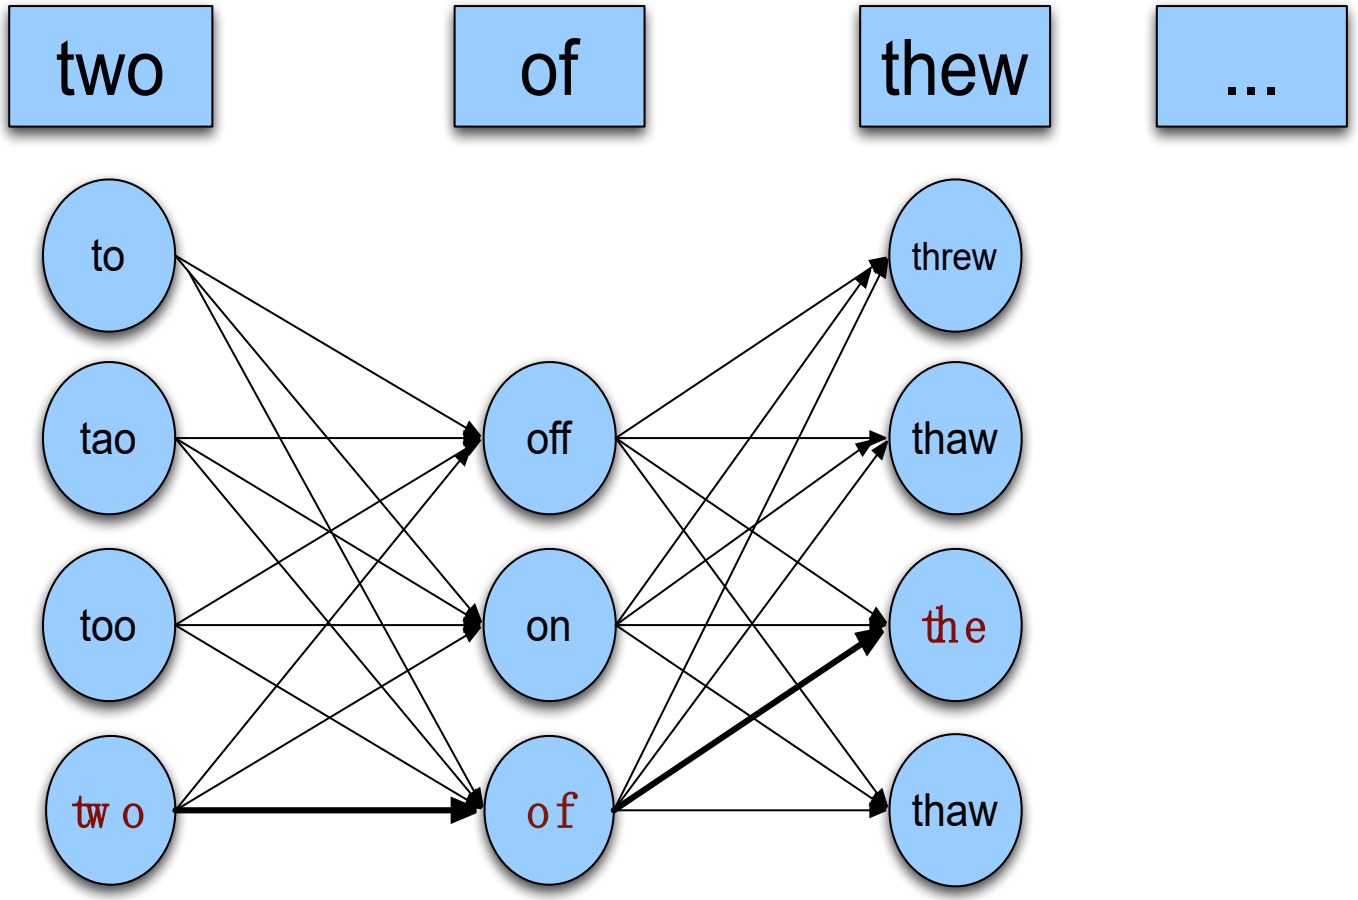

简化：每句话仅考虑一个错误

只考虑（与输入查询）仅有一个词不同的句子

w_1, w''_2, w_3, w_4 two off thew

w_1, w_2, w'_3, w_4 two of the

w'''_1, w_2, w_3, w_4 too of thew

…

选择使得 概率P(W)最大的序列W

怎样计算概率

语言模型

- 一元（Unigram）
- 二元（Bigram）
- 三元（trigram）等等...

通道模型

- 与非词汇拼写矫正相同
- 需要额外考虑无拼写错误概率, $P(w|w)$

无错误概率

什么是正确拼写词的通道概率（What is the channel probability for a correctly typed word）？

P(“the”|“the”)

在大语料的支持下，可以准确的估计概率

但是概率值很大程度上取决于应用

.90 (1 error in 10 words)

.95 (1 error in 20 words)

.99 (1 error in 100 words)

Peter Norvig's "thew (肌肉力量)" example

x	w	x|w	P(x|w)	P(w)	10^9 P(x|w)P(w)
thew	the	ew|e	0.000007	0.02	144
thew	thew		0.95	0.00000009	90
thew	thaw	e|a	0.001	0.0000007	0.7
thew	threw	h|hr	0.000008	0.000004	0.03
thew	thwe	ew|we	0.000003	0.00000004	0.0001

当前最佳的噪声通道

We never just multiply the prior and the error model（不仅仅是把先验概率和错误模型相乘）

Independence assumptions→probabilities not commensurate（这是因为：由于独立性假设，这两个概率不相称）

Instead: Weight them（替代方案是为概率赋权重）

$$\hat{w} = \underset{w \in V}{\operatorname{argmax}} P(x \mid w) P(w)^{\lambda}$$

Learn λ from a development test set（在开发集上学习参数λ）(由于使用对数概率，λ其实是一个线性系数)

通道模型的改进

允许更丰富的编辑操作 (Brill and Moore 2000)

- ent→ant
- ph→f
- le→al

这三个都是同音节替换

将发音融入到通道模型中 (Toutanova and Moore 2002)

将设备融入到通道模型中

- （虽然）并非所有的安卓手机都需要相同的错误模型
- 但是拼写矫正方案可以在系统级别进行设计（即针对不同的系统/输入法 设计/训练不同的错误模型）